1 Graph Neural Networks - GNNs

GNNs predstavljaju deo oblasti graph mašinskog učenja (GraphML), koje u sebi eksplicitno implementiraju koncepte dubokog učenja. Sa stanovišta teorije dubokog učenja, kojom smo se najviše bavili na kursu, GNNs su samo još jedna arhitektura neuralnih mreža, koja je prilagođena za podatke grafovskog tipa. Ovde pre svega podrazumevamo podatke u kojima je moguće uspostaviti određene grafovske relacije, a što je posledica ili same prirode (kompleksnog) sistema gde su podaci nastali (Natural graphs) ili načina na koji ih koristimo pri modelovanju problema (Synthetic graphs). Ispostavlja se da je ovakav pristup vrlo koristan, jer nam daje mogućnost da model obogatimo sa dodatnom informacijom o relacijama među komponentama sistema. GNNs imaju široke primene u različitim oblastima poput ekonomije, socijalnih nauka, transporta i bioinformatike. Pre nego dođemo do konkretnog projektovanja mreže, iznećemo važne teorijske elemente ovog modela. Trudićemo se da napravimo analogiju sa konvolucionim neuralnim mrežama.

2 Teorijski Aspekti GNNs

2.1 Motivacija

Kako bi opisali GNNs trudićemo se napravimo analogiju sa CNNs. Prvo treba prokomentarisati da za razliku od FCNNs, CNNs imaju sposobnost da se nose sa podacima velikih dimenzija i pri tome veoma dobro identifikuju informacije od interesa. U realnim primenama grafovi su veoma veliki, a mi zasigurno želimo da izvučemo što je moguće više iz njegove strutkture (relacije među komponentama), te su nam upravo osobine CNNs glavni vodič. Treba reći da su slike linearna matrična struktura podataka, a grafovi vrlo opšta nelinearna struktura, te same po sebi CNNs ne mogu tek tako da se primene na ovaj tip podataka. Međutim, ako uzmemo u obzir da je ključni element uspeha CNNs primena konvolucije, upravo to ćemo da iskoristimo za formiranje GNNs.

Konvolucija je postupak koji nam je već konceptualno poznat, kako iz analize linearnih sistema i digitalne obrade signala, tako i u radu sa 2d signalima, kao što su slike. Kako bi uspeli da definišemo konvoluciju na grafovima, neophodno je, prvo, uvesti određene matematičke pojmove. Ispostavlja se da je konvolucija na grafovima generalniji koncept, te se kroz neke oblike grafova može postići efekat koji odgovara konvoluciji u vremenu i prostoru, međutim time se nećemo baviti u ovom izveštaju.

2.2 Matrična teorija grafova

Definicija: Graf predstavlja uređenu trojku $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$, gde su $\mathcal{V}$ čvorovi, $\mathcal{E}$ grane i $\mathcal{W}$ težine.
Čvorovi su skup n labela. Tipično označani kao $\mathcal{V} = \{1, .., n\}$.
Grane su skup uređenih parova čvorova (labela) (i, j). Za razliku od klasične

konvencije u teoriji grafova, ovde za granu (i, j) smatramo da je strelica usmerena od j, ka i.
Težine realne, najčešće pozitivne, vrednosti w_{ij} dodeljene granama grafa.
Ovako definisan graf odgovara usmerenom, težinskom grafu. Ukoliko su grane i težine simetrične (postojanje grane (i, j) implicira postojanje grane (j, i) i važi $w_{ij} = w_{ji}$), radi se o neusmerenom težinskom grafu. Ako su sve težine jedinične vrednosti radi se neusmerenom netežinskom grafu (koji se u literaturi i češće naziva samo graf).

Definicija: Matrica susedstva (Adjecancy matrix) grafa $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ je retka matrica $\mathbf{A}$ sa nenultim elementima datim sa $\mathbf{A}_{ij} = w_{ij}$, za svako $(i, j) \in \mathcal{E}$. Kod neusmerenih grafova važi $\mathbf{A} = \mathbf{A}^T$, dok za netežinske važi $\mathbf{A}_{ij} = 1$, za svako $(i, j) \in \mathcal{E}$.

Definicija: Deegree matrix je dijagonalna matrica $\mathbf{D}$ takva da važi da je $\mathbf{D}_{ii} = d_i$, gde je $d_i = \sum_{j \in n(i)} w_{ij}$, gde je $n(i) = \{j : (i, j) \in \mathcal{E}\}$.
Važi relacija $\mathbf{D} = \text{diag}(\mathbf{A1})$

Definicija: Laplasova matrica je matrica $\mathbf{L}$ takva da važi $\mathbf{L} = \mathbf{D} - \mathbf{A}$.
Laplasova matrica $\mathbf{L}$ je vrlo važna u spektralnoj analizi grafova. Treba imati u vidu da pored matrica $\mathbf{A}$ i $\mathbf{L}$, postoje njihove normalizovane verzije $\bar{\mathbf{A}}$ i $\bar{\mathbf{L}}$, međutim ovde to nećemo detaljno diskutovati.

Definicija: Graf shift operator $\mathbf{S}$ je svaka matrična reprezentacija grafa $\mathcal{G}$ poput $\mathbf{A}, \mathbf{L}, \bar{\mathbf{A}}, \bar{\mathbf{L}}$.
Izbor operatora zavisi od praktičnih zahteva ali većina svojstava važi za različito $\mathbf{S}$.

2.3 Graf signali

Definicija: Neka je dat graf $\mathcal{G}$ sa n čvorova i shift operatorom $\mathbf{S}$, graf signal je vektor $\mathbf{x} \in \mathbf{R}^n$, pri čemu je vrednost komponente x_i odgovara čvoru i. Kako bi iskazali da je signal $\mathbf{x}$ dodeljen grafu $\mathcal{G}$ možemo zapisati u obliku uređenog para kao $(\mathbf{S}, \mathbf{x})$.

Na dalje nam je od koristi posmatrati proizvod $y = \mathbf{Sx}$. U literaturi se signal y naziva *diffused signal*. Primetno je da će komponente signala y biti linearna kombinacija komponenti signala x, i to onih između čijih čvorova postoji grana, što zaista liči na određeni oblik difuzije. Ako odemo korak dalje i definišemo proces difuzije dat sa $\mathbf{x}[\mathbf{k}+\mathbf{1}] = \mathbf{S}\ \mathbf{x}[\mathbf{k}]$ i $\mathbf{x}[\mathbf{0}] = \mathbf{x}$, ispostavlja se da za male k imamo izražena lokalna svojstva grafa, dok za veliko k globalna svojstva grafa dolaze do izražaja. Dakle, određen oblik kretanja od lokalnih ka globalnim osobinama. Ovo bi se moglo interpretirati i opravdati sa tačke teorije upravljanja.

2.4 Graf filtri i konvolucija

Definicija: Za zadati shift operator $\mathbf{S}$ i koeficijente h_k, graf filter je dat kao polinom (red) po $\mathbf{S}$, $\mathbf{H}(\mathbf{S}) = \sum_{k=0}^{\infty} h_k \mathbf{S}^k$.
Rezultat primene filtera $\mathbf{H}(\mathbf{S})$ na graf signal $\mathbf{x}$, je graf signal $\mathbf{y} = \mathbf{H}(\mathbf{S})\mathbf{x} = \sum_{k=0}^{\infty} h_k \mathbf{S}^k \mathbf{x}$.

Zapisujemo $\mathbf{y} = \mathbf{h} *_{\mathbf{S}} \mathbf{x}$ i kažemo da je $\mathbf{y}$ *graf konvolucija* filtra $\mathbf{h} = \{h_k\}_{k=0}^{\infty}$ i graf signala $\mathbf{x}$. Za slučaj $\mathbf{h} = \{h_k\}_{k=0}^{K-1}$, imamo filtar reda K.
Treba napomenuti da filtar ne zavisi od grafa, te da se isti filtri mogu primenenjivati na različite arhitekture grafova. Međutim izlazni signal zavisi od tipa filtra, a dalje i od oblika grafa i graf signala koji filtriramo.
Uzimajući sve ovo u obzir, ispostavlja se da graf konvolucija agregira informacije od lokalne ka globalnoj prirodi, što u kontekstu grafa znači bolje razumevanje lokalnih i globalnih veza među čvorovima (bliskih i udaljenih čvorova). Dakle, zaključak je da ovako definisani graf filtri imaju sposobnost da ekstrakuju različita obeležja, koja mogu nositi dosta informacije o prirodi grafa.

Ako bi priču širili dalje, uvodi se GFT (Graph Fourier Transform) signala, impulsni odziv i frekvencijski domen gde se i bolje vidi kako različiti filtri transformišu ulazni signal, tj. filtriraju različita obeležja. Nije loše istaći da je čitava teorija vrlo slična klasičnoj digitalnoj obradi signala, međutim u to nećemo ovde ulaziti. Glavna stvar je da smo ostvarili mehanizam koji ima analogan efekat na graf, kakav je prisutan u konvoluciji sa slikama.

2.5 Arhitektura GNNs

Slično FCNN i CNN, uvodimo pojam graf perceptrona. Gde je $\sigma[\mathbf{z}]$ neka od standardnih nelinearnosti koje se koriste u neuralnim mrežama.

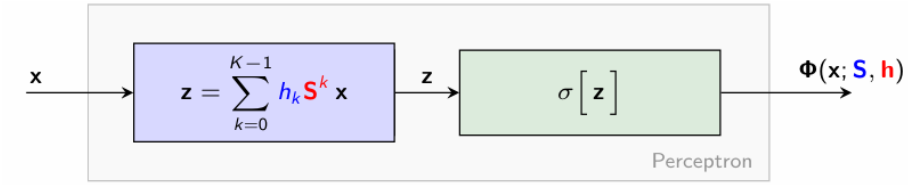

Slika 1: Graf perceptron

Osnovna arhitektura GNN nastaje kompozicijom graf filtera i karakterističnih nelinearnosti. Na slici ispod je dat jedan takav primer

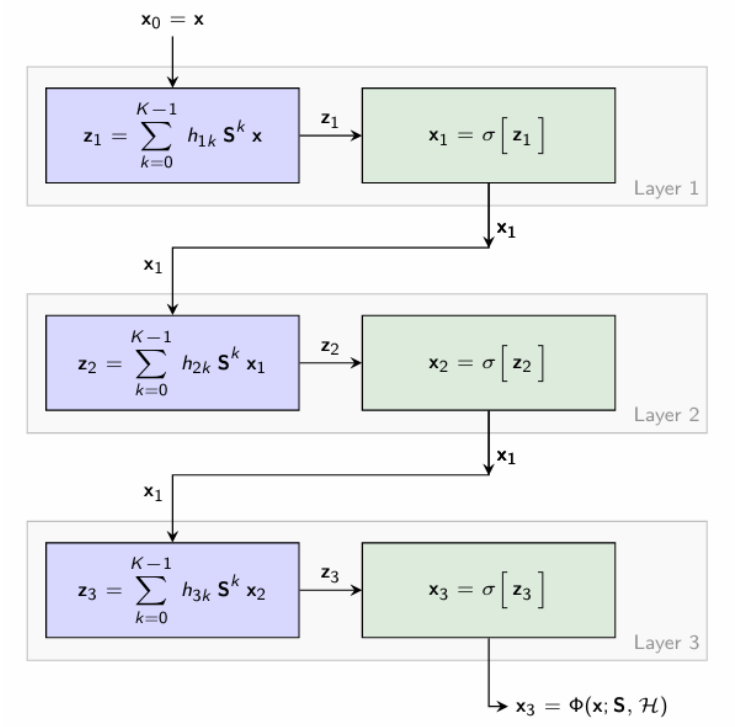

Slika 2: Osnovna arhitektura GNNs

Gornju aritekturu možemo opisati sledećom rekurzivnom relacijom $\mathbf{x}_l = \sigma(\mathbf{z}_l) = \sigma(\sum_{k=0}^{K-1} h_{lk}\mathbf{S}^k\mathbf{x}_{l-1})$

Analogno CNNs, želimo da na nivou jednog sloja ekstrakujemo više različitih obeležja, osim da idemo samo po dubini mreže (kao što prikazuje gornja arhitektura). Ovo nas dovodi do toga da ćemo na izlazu jednog sloja primeniti više različitih filtara, te da će izlaz sloja sada biti matrica graf signala. U GNNs teoriji se za ovakav postupak izdvajanja više obeležja po sloju, kaže da koristimo Graph Filter Banks.

Izlaz graf filter banki je kolekcija više graf signala, data u matričnoj formi $\mathbf{Z} = [\mathbf{z^1}, ..., \mathbf{z^F}]$. Ovde imamo matrični graf signal dimenzije F, što je po F obeležja za svaki čvor, a gde $\mathbf{z^f}$ predstavlja obeležja svakog čvora, koja su rezultat filtracije f-tim filtrom, dakle $\mathbf{z^f}$ je jedan graf signal tj. rezultat jedne od F filtracija. Mnogo je lakše vizuelno zamisliti.

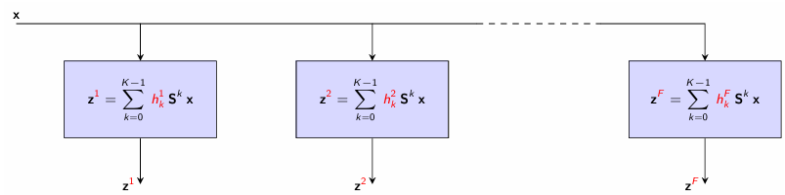

Slika 3: Postupak filtracije

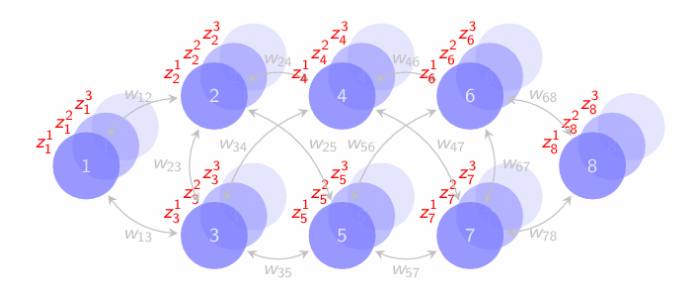

Slika 4: Izlaz graf filter banki

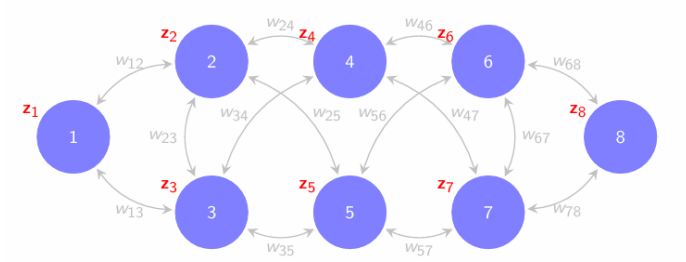

Slika 5: Svakom čvoru je sada dodeljene vektor dimenzije F

Postupak se sada može generalizovati. Neka je svakom čvoru dodeljen vektor sa F komponentni, slično kao što je prikazano na Slici 5, ukoliko želimo da ovako definisan graf signal filtriramo filter bankom dimenzije G, postupak je sledeći.

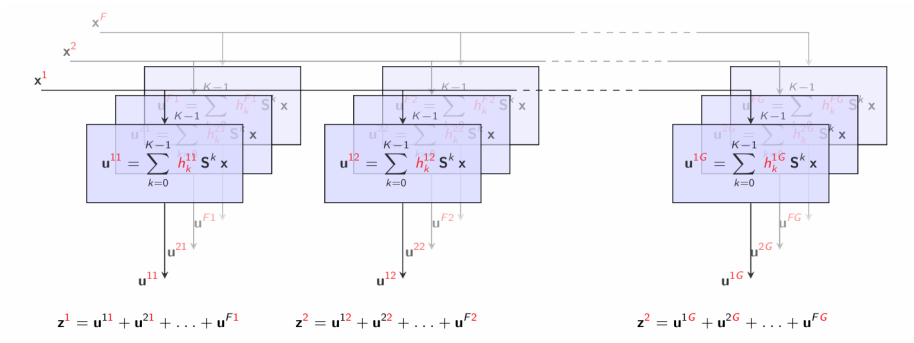

Slika 6: Izlaz graf banke pri filtraciji FxG filtraciji

Rezultat ovakve filtracije se može kompaktno zapisati u matričnoj formi kao

$$\mathbf{Z} = [\mathbf{z}^1 \ \ldots \ \mathbf{z}^g \ \ldots \ \mathbf{z}^G] = \sum_{k=0}^{K-1} \mathbf{S^k X H_k}$$

gde su $\mathbf{X} = [\mathbf{x^1} \ \ldots \ \mathbf{x^f} \ \ldots \ \mathbf{x^F}]$ i $(\mathbf{H_k})_{\mathbf{fg}} = h_k^{fg}$.

Kompozicijom gornjih postupaka filtracije uz uvođenje karakterističnih nelinearnosti, konačno možemo dati finalnu arhitekturu graf neuralne mreže.

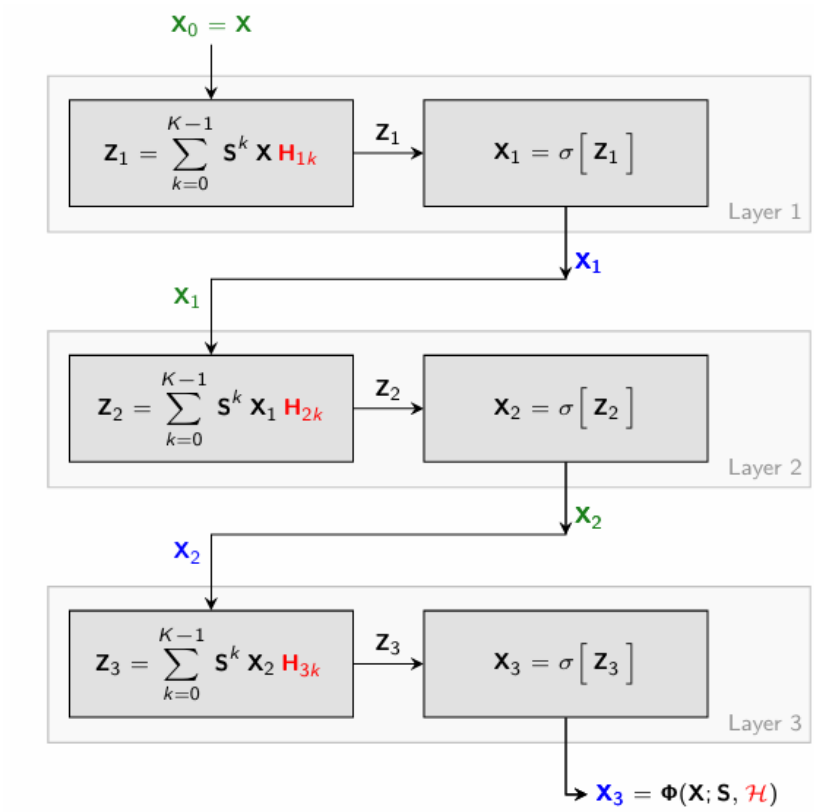

Slika 7: Izlaz graf banke pri filtraciji FxG filtraciji

Ovo se može opisati rekurzivnom relacijom $\mathbf{X}_l = \sigma(\mathbf{Z}_l) = \sigma(\sum_{k=0}^{K-1} \mathbf{S}^k \mathbf{X}_{l-1} \mathbf{H}_{lk})$

3 Dodatne napomene i osobine GNNs

Izlaz graf neuralne mreže je dat u formi $\mathbf{X}_{out} = \mathbf{\Phi}(\mathbf{X}; \mathbf{S}, \mathcal{H})$, pri čemu je $\mathbf{X}$ ulaz u mrežu, $\mathbf{S}$ shift operator koji odgovara grafu i to je hiperparametar pomoću koga unosimo apriorne znanje o relacijama u podacima i $\mathcal{H}$ koeficijenti graf filtara (filtar tenzor), koju su zapravo trenirajući parametri. Kao i u ostalim neuralnim mrežama problem treniranja je sveden na odabir hiperparametara $\mathcal{H}$, tako da važi:

$$\mathcal{H}^* = \arg\min_{\mathcal{H}} \sum_{(x,y)\in\tau} l(y,\ \mathbf{\Phi}(\mathbf{X}; \mathbf{S}, \mathcal{H}))$$

gde je $l(y, \hat{y})$ odgovarajuća loss funkcija, a τ trening skup.
Ostali koncepti optimizacija i zaštita od preobučavanja neuralnih mreža slično važe i kod graf neuralnih mreža (posebno je interesantan dropout).

Treba imati u vidu da je filtracija graf signala, linearna transformacija. Kod standardnih FCNN, takođe imamo linearnu transformaciju, ali sa više stepeni slobode. Ovo nam govori da su ipak FCNN generalniji koncept, te da upravo definisanjem grafa ugrađujemo dodatno znanje i smanjujemo stepene slobode.

U literaturi je poznato da FCNNs kao opštiji model, vrlo često prave manju grešku od GNNs na trening skupu, međutim u najvećem broju slučaja GNNs imaju bolju tačnost na test skupu. Dakle, GNNs imaju dobru moć generalizacije čemu doprinosi osobina permutation equivariance, o čemu ovde nećemo diskutovati.

Već smo rekli da se graf konvolucija u specijalnim slučajevima grafova može svesti na ekvivalent konvoluciji na slikama, te se u tom smislu GNNs mogu posmatrati kao uopštenje CNNs.

4 Sistemi preporučivanja

Sistem za preporučivanje je klasa mašinskog učenja koja koristi podatke kako bi pomogla u predviđanju, sužavanju i pronalaženju izbora u eksponencijalno rastućem broju opcija.
Ovakvi sistemi su obučeni da razumeju preference, prethodne odluke i karakteristike korisnika i proizvoda, na osnovu podataka o njhihovim ranijim aktivnostima. Neki od kriterijuma na kojima se ovi sistemi zasnivaju su: istorija pretrage, impresije, demografske karakteristike, lajkovi, komentari itd.
Algoritmi za preporučivanje se obično mogu svrstati u jednu od tri kategorije, i to: kolaborativno filtriranje, filtriranje sadržaja i filtriranje konteksta.
Kolaborativno filtriranje: Preporučuje stavke (filtrira), na osnovu preferenci mnogih korisnika (kolaboracija). Ideja je ako su neki korisnici donosili slične odluke u prošlosti (sličan ukus), velika je verovatnoća da će se složiti oko budućih izbora.
Filtriranje sadržaja: Koristi obeležja (korišćenih) stavki kako bi preporučilo druge stavke slične korisničkim preferencijama. Posmatra se sličnost između karakteristika stavki i korisnika, pri čemu se na osnovu korisničkih interakcija sa

ranijim stavkama modelira verovatnoća poklapanja sa novim stavkama.
Kontekstualna filtracija: Koristi se niz ranijih kontekstualnih korisničkih radnji i trenutni kontekst, kako bi se predvidela verovatnoća sledeće radnje. Ovo obično podrazumeva rad sa nekim dinamičkim modelima mašinskog i dubog učenja.
Neki od modela koji se koriste ili su se koristili u projektovanju ovakvih sistema su: matrične faktorizacije za preporučivanje, HMM, GNNs, Graph Transformers, DNNs, DLRM, W&D, NCF, BERT i posebno novije tehnike poput LLMs i RAG.

5 Implementacija

5.1 Ulazni podaci

Ulazni skup podataka se sastoji od fajlova movies.csv, ratings.csv, links.csv i tags.csv, koji su međusobno spregnuti. Za projektovanje sistema za preporuku od interesa će nam biti fajlovi movies.csv i ratings.csv, a naš sistem će biti zasnovan na pristupu kolaborativne filtracije. Pri radu sa velikim podacima važno je postaviti cilj rada, tako da će naš prvi cilj biti osnovna deskriptivna statistička analiza i konstrukcija bipartitivnog grafa, kako bi mogli bolje da razumemo sa kakvim informacijama, zapravo raspolažemo.

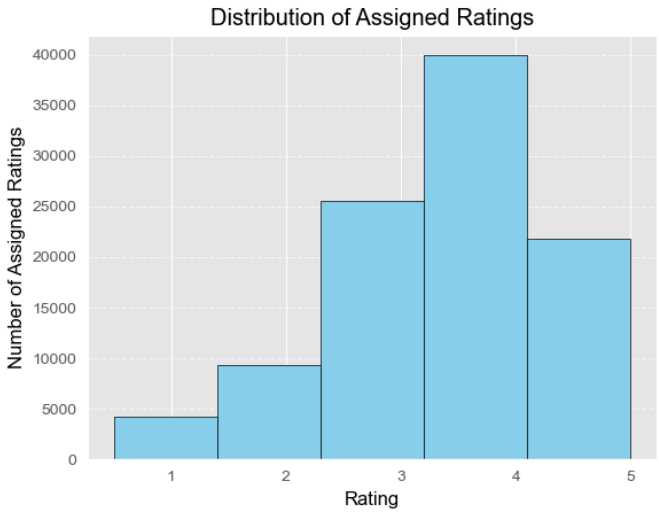

Slika 8: Raspodela svih dodeljenih ocena

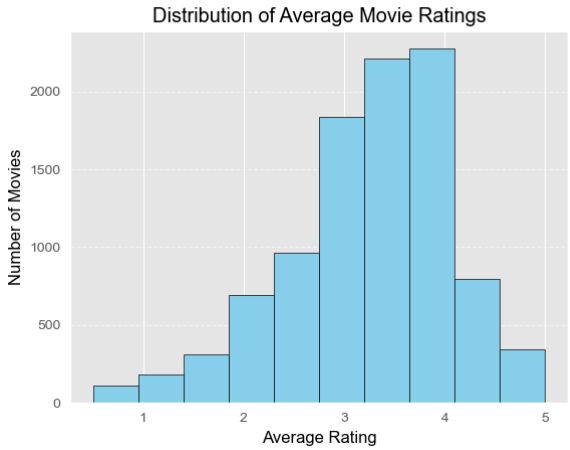

Slika 9: Raspodela prosečnih ocena po filmu

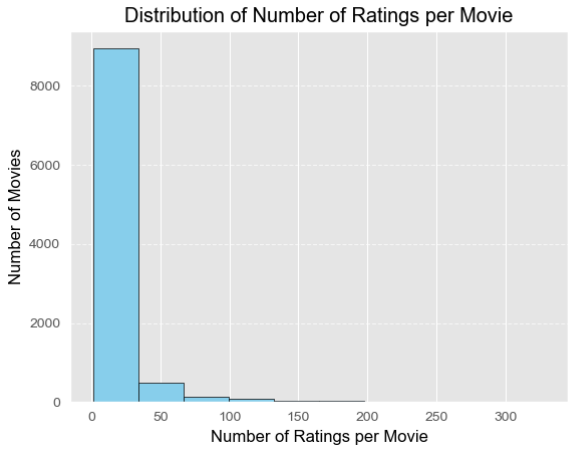

Slika 10: Raspodela broja dodeljenih ocena po filmu

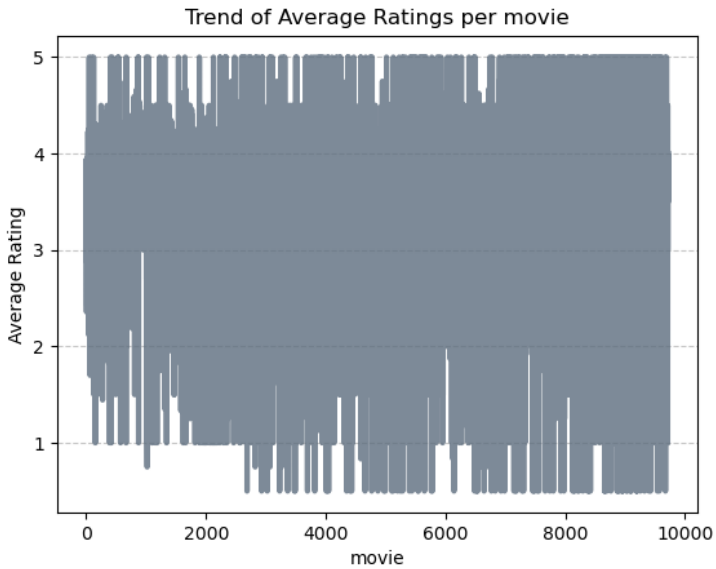

Slika 11: Trend prosečno datih ocena po filmovima

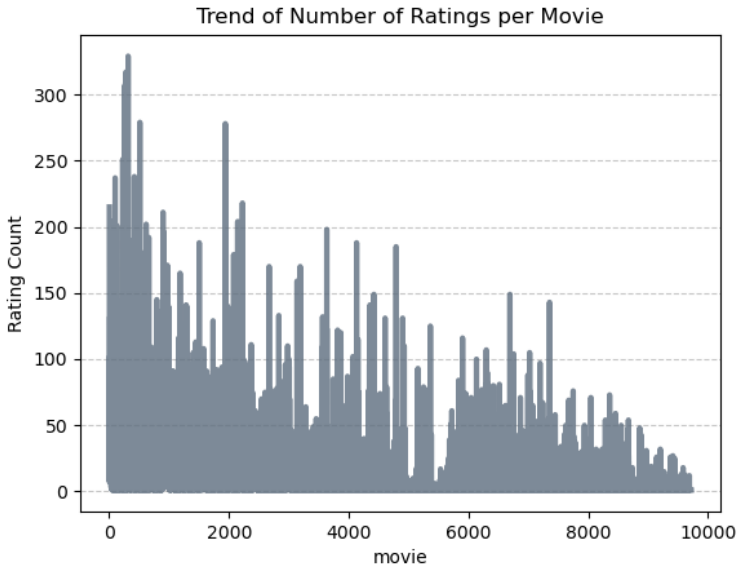

Slika 12: Trend broja ocena datih po filmu

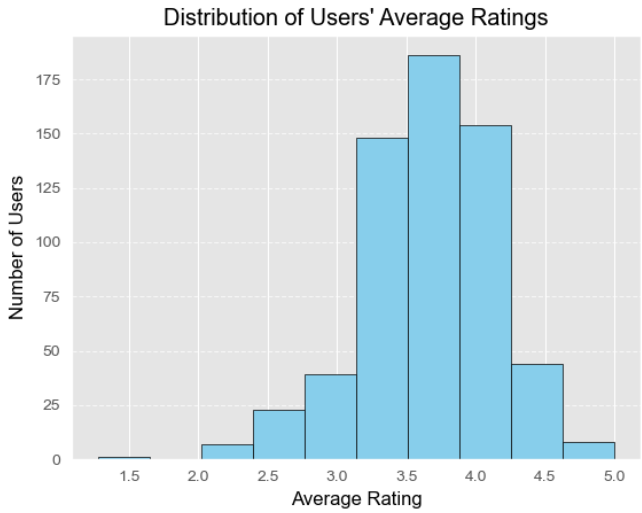

Slika 13: Raspodela prosečno datih ocena po korisnicima

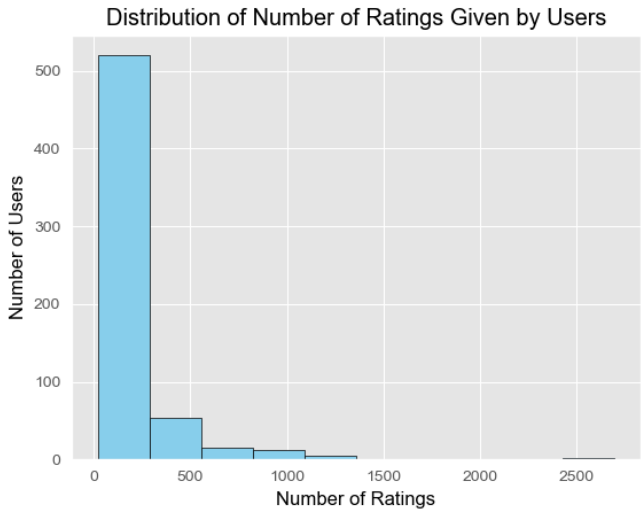

Slika 14: Raspodela broja datih ocena po korisnicima

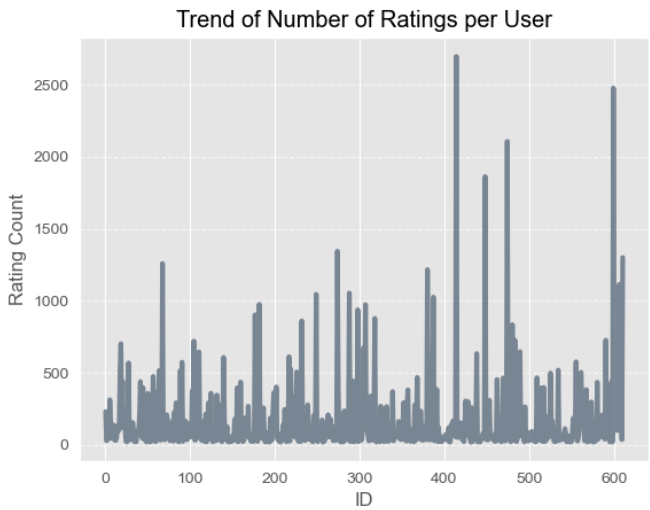

Slika 15: Trend broja ocena datih po korisniku

5.2 Konstrukcija grafa

Definicija: Bipartitivni usmereni težinski graf G definisan je kao $G = (V, E, w)$, gde je:

- $V = U \cup V'$ disjunktna unija dva skupa čvorova ($U \cap V' = \emptyset$),
- $E \subseteq (U \times V') \cup (V' \times U)$ skup usmerenih ivica (bez ivica unutar U ili V'),
- $w : E \to \mathbb{R}^+$ funkcija težina koja dodeljuje svakoj ivici $e \in E$ pozitivnu realnu vrednost $w(e)$.

Svaka ivica $e = (u, v) \in E$ ima eksplicitan smer od čvora u ka čvoru v, pripadajući različitim particijama.

U našem kontekstu disjunktne podskupe će činiti skup filmova i skup korisnika, pri čemu će graf biti usmeren tako da smer grane ide od korisnika ka filmu, dok će težine grana odgovarati oceni koju je korisnik dodelio filmu.
Graf će biti dosta veliki i biće težak za prikazivanje, pa ćemo se potruditi da damo neke statistike i u nekoj meri ga skiciramo.
Broj čvorova: 2879, broj grana: 81116.

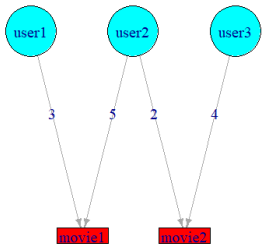

Slika 16: Skica grafa

Prikaz dominantnih korisnika

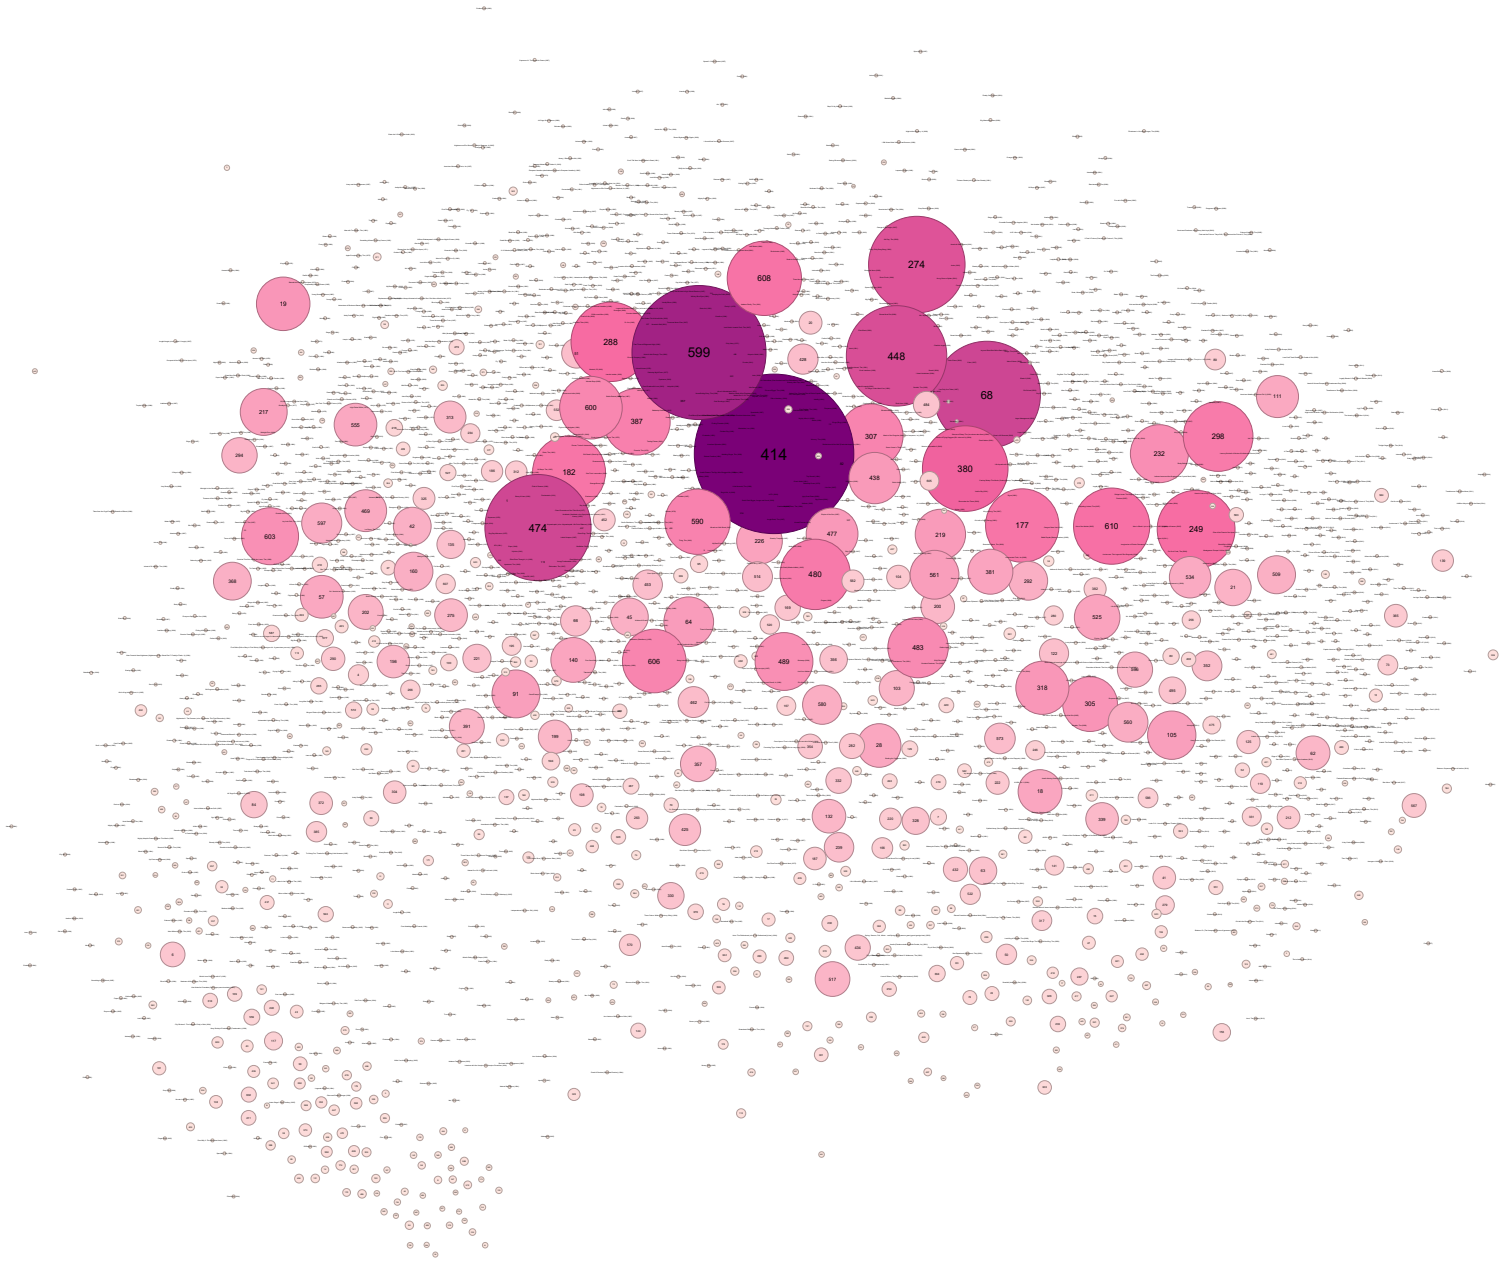

Prikaz dominantnih filmova

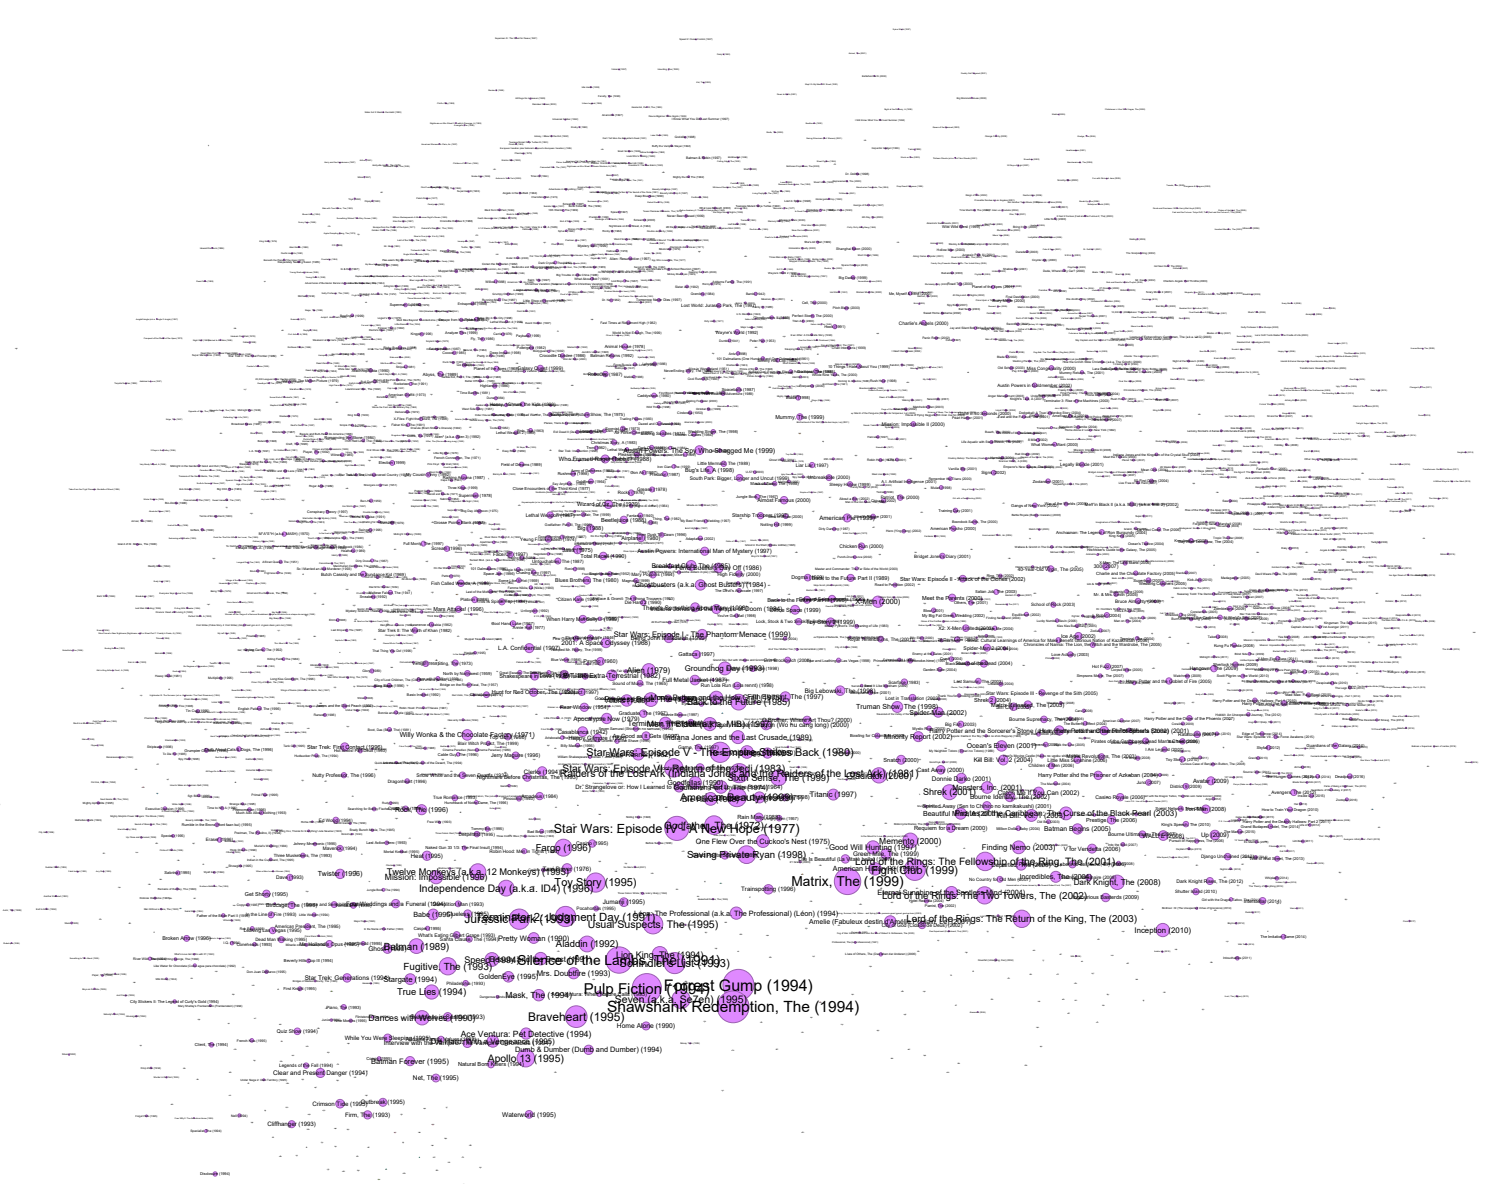
Pulp Fiction (1994)
Forrest Gump (1994)
Shawshank Redemption, The (1994)
Silence of the Lambs, The (1991)
Braveheart (1995)
Apollo 13 (1995)
Fugitive, The (1993)
True Lies (1994)
Mask, The (1994)
Dances with Wolves (1990)
Aladdin (1992)
Usual Suspects, The (1995)
Toy Story (1995)
Independence Day (a.k.a. ID4) (1996)
Twelve Monkeys (a.k.a. 12 Monkeys) (1995)
Fargo (1996)
Star Wars: Episode IV - A New Hope (1977)
Saving Private Ryan (1998)
Matrix, The (1999)
Fight Club (1999)
Lord of the Rings: The Fellowship of the Ring, The (2001)
Lord of the Rings: The Return of the King, The (2003)
Lord of the Rings: The Two Towers, The (2002)
Star Wars: Episode V - The Empire Strikes Back (1980)
Star Wars: Episode VI - Return of the Jedi (1983)
Raiders of the Lost Ark (Indiana Jones and the Raiders of the Lost Ark) (1981)
Sixth Sense, The (1999)
Terminator, The (1984)
Groundhog Day (1993)
Star Wars: Episode I - The Phantom Menace (1999)
Jurassic Park (1993)
Independence Day (1996)
Pretty Woman (1990)
Batman (1989)
Mrs. Doubtfire (1993)
Golden Eye (1995)
Stargate (1994)
Star Trek: Generations (1994)
Babe (1995)
Jumanji (1995)
Clear and Present Danger (1994)
Home Alone (1990)
Ace Ventura: Pet Detective (1994)
Dumb & Dumber (Dumb and Dumber) (1994)
Batman Forever (1995)
Nat. Tres (1995)
Firm, The (1993)
Cliffhanger (1993)
Waterworld (1995)
Crimson Tide (1995)
Dracula (1992)
Truman Show, The (1998)
Minority Report (2002)
Ocean's Eleven (2001)
Shrek (2001)
Donnie Darko (2001)
Beautiful Mind, A (2001)
Pirates of the Caribbean: The Curse of the Black Pearl (2003)
Finding Nemo (2003)
Memento (2000)
Good Will Hunting (1997)
One Flew Over the Cuckoo's Nest (1975)
Titanic (1997)
Batman Begins (2005)
Incredibles, The (2004)
Dark Knight, The (2008)
Inception (2010)
Mummy, The (1999)
Austin Powers: International Man of Mystery (1997)
Shrek 2 (2004)
Spider-Man (2002)
Star Wars: Episode II - Attack of the Clones (2002)
Harry Potter and the Sorcerer's Stone (a.k.a. Harry Potter and the Philosopher's Stone) (2001)
Harry Potter and the Prisoner of Azkaban (2004)
Harry Potter and the Chamber of Secrets (2002)
Harry Potter and the Goblet of Fire (2005)
Harry Potter and the Order of the Phoenix (2007)
Pirates of the Caribbean: At World's End (2007)
Pirates of the Caribbean: Dead Man's Chest (2006)
Casino Royale (2006)
Ghost Busters (a.k.a. Ghost Busters) (1984)
Back to the Future (1985)
Back to the Future Part II (1989)
Back to the Future Part III (1990)
Star Wars: Episode III - Revenge of the Sith (2005)
Spider-Man (2002)
Spider-Man 2 (2004)
Spider-Man 3 (2007)
Superman (1978)
Superman II (1980)
Superman III (1983)
Superman IV: The Quest for Peace (1987)
Superman Returns (2006)
Batman (1989)
Batman Returns (1992)
Batman Forever (1995)
Batman & Robin (1997)
Batman: Mask of the Phantasm (1993)
Batman Begins (2005)
Dark Knight, The (2008)
Dark Knight Rises, The (2012)
Shutter Island (2010)
Inception (2010)
Avatar (2009)
Up (2009)
Up (2009)
Up

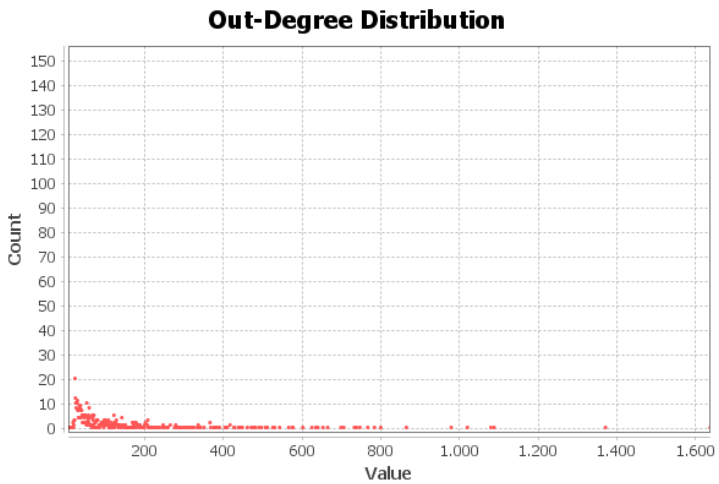

Slika 17: Raspodela izlaznog stepena čvorova - $f_{d_{in}}$

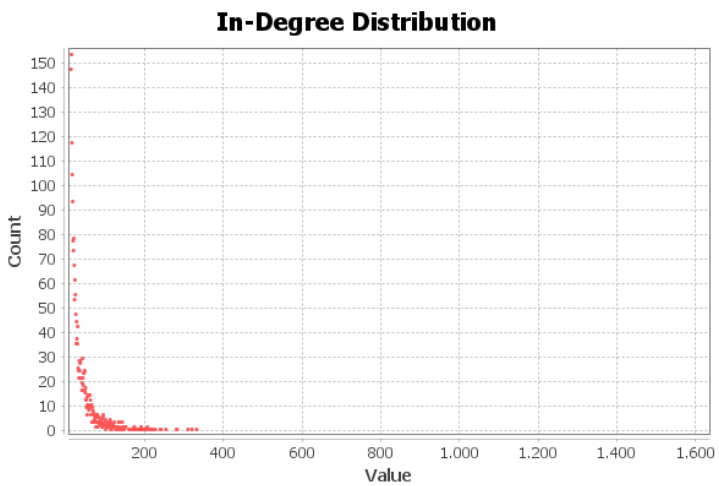

Slika 18: Raspodela ulaznog stepena čvorova - $f_{d_{out}}$

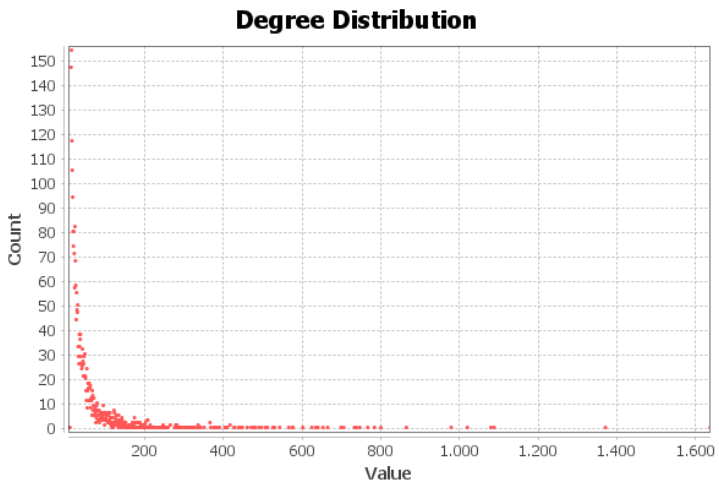

Slika 19: Raspodela ukupnog stepena čvorova $f_{d_{in}+d_{out}}$

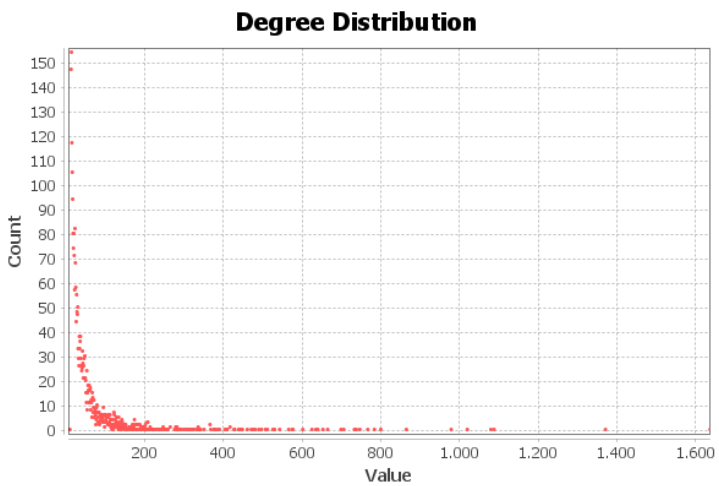

Slika 20: Raspodela ukupnog stepena čvorova $f_{d_{in}+d_{out}}$

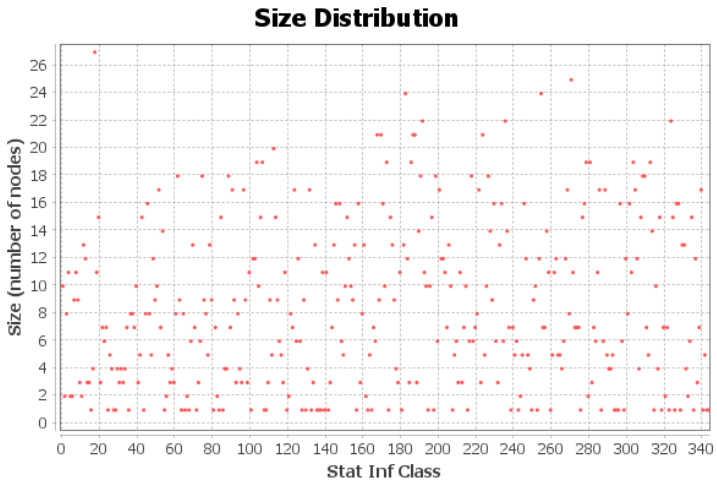

Slika 21: Raspodela veličina detektovanih zajednica u grafu

5.3 Formiranje trening grafa

Bipartitivni graf može poslužiti kao model za treniranje graf neuralnih mreža, međutim zbog svoje kompleksnoti i neiskorišćenosti informacija vrlo često se koriste drugi modeli. U našem slučaju, za treniranje graf neuralne mreže koristićemo graf sličnosti koji je dat sa modifikovanom kovarijacionom matricom, kao matricom susedstva. Ideja je da samo filmove posmatramo kao čvorove, pri čemu će težine, sada neusmerenih grana, biti date kao korelacije između odgovarajučih čvorova. Treba napomenuti da pri kreiranju grafova sličnosti, postoje različiti načini da se definiše funkcija sličnosti.

U ovom koraku početni data skup delimo na trening i test skup u razmeri 80:20. Na osnovu trening skupa formiramo korelacionu matricu, pri čemu postvljamo uslov da je za uspostvljanje nenulte korelacije među filmovima neophodno da ih je bar minUser = 10 istih korisnika ocenilo. Kako bi umanjili šum i numeričke nestabilnosti, za svaki film uzećemo samo nMax = 35 najvećih vrednosti korelacija sa drugim filmovima, dok ostale postavljamo na nulu.

Ovako definisana matrica ima nenulte dijagonalne elemente, što u kontekstu grafa znači postojanje petlje na svim čvorovima, te je u tom smislu dijagonalnim elementima potrebno staviti vrednost 0. Takođe ovako formirana matrica susedstva, vrlo lako može imati komponente koje nisu povezane, pa u tom smislu za naš finalni graf uzimamo samo najveću povezanu komponentu. Kao rezultat dobijamo matricu $\mathbf{W}$, koju posmatramo kao matricu susedstva, tj. dalje je njom definisan shift operator. Korelacija između filmova, funkcija sličnosti u ovom slučaju, je data kao:

$$\sigma_{ij} = \frac{1}{\#(\mathcal{U}_{ij})} \sum_{u \in \mathcal{U}_{ij}} (x_{ui} \ - \ \mu_{ij})(x_{ui} \ - \ \mu_{ji})$$

gde je

$$\mu_{ij} = \frac{1}{\#(\mathcal{U}_{ij})} \sum_{u \in \mathcal{U}_{ij}} x_{ui}, \quad \mu_{ji} = \frac{1}{\#(\mathcal{U}_{ij})} \sum_{u \in \mathcal{U}_{ij}} x_{ui}$$

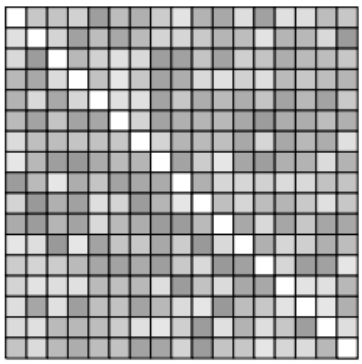

Slika 22: Skica adekvatne korelacione matrice

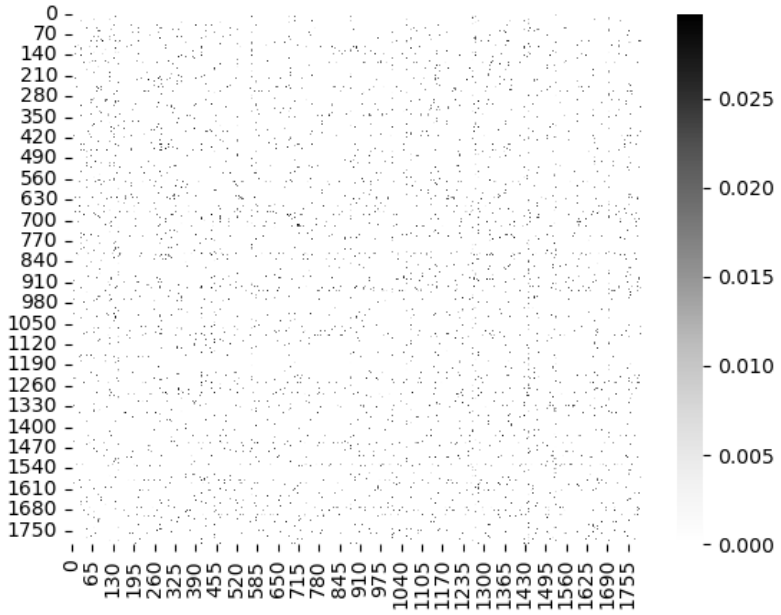

Slika 23: Pregled prave korelacione matrice

Neusmeren graf formiran na osnovu ovakve matrice ima 1797 čvorova i 36766 grana.

5.4 Postupak treniranja, normalizacija i loss funkcija

Kako smo formirali graf, neophodno je definisati graf signale i potupak treniranja. Za rad jednostavnije ilustacije pretpostavimo da nam je matricom $\mathbf{W}$ definisan graf od 4 filma. Graf signali su ocene koje (ni)je korisnik dao datim filmovima.

Pretpostavimo da je UserK je dao sledeće ocene $X_k = [x_1\ 0\ x_3\ x_4]$. Naš cilj je da na osnovu ovakve informacije procenimo x_2. Prema tome treniranje mreže ćemo koncipirati tako da uzmemo sve korisnike koje su dali ocenu filmu dva $X^i = [x_1^i\ x_2^i\ x_3^i\ x_4^i]$, $x_2^i \neq 0$. Formiramo sledeći trening par $X_{in}^i = X^i - [0\ x_2^i\ 0\ 0] = [x_1^i\ 0\ x_3^i\ x_4^i]$, $Y_{out}^i = [0\ x_2^i\ 0\ 0]$ i sprovodimo klasičan postupak treniranja mreže. Dakle treniranje mreže vršimo po filmu.
Kao loss funkciju koristili smo srednje-kvadratnu grešku po filmu za koji predviđamo ocenu. Ukoliko je $\hat{x}_2^i$ predikcija našeg modela, loss funkcija je data kao

$$l(x_2^i,\ \hat{x}_2^i) = \frac{1}{2}(x_2^i - \hat{x}_2^i)^2$$

Interesantno je napomenuti da će pri predikciji ocene x_2 modela da da i neke vrednosti za preostale filmove, međutim to je samo rezultat graf filtracije te ostale vrednosti nisu relevantne za nas.

Postoje različiti pristupi za normalizaciju podataka pri treniranju graf neuralnih mreža, ali mi ćemo iskoristiti normalizaciju spektralnim radijusom, tj. normalizaciju nuklearnom normom matrice $\mathbf{W}$. Matrica koju ćemo zapravo koristiti je normlizovana matrica $\mathbf{W}^* = \frac{1}{\mathcal{R}}\mathbf{W}$, gde je, $\mathcal{R} = \max\lambda_{\mathrm{i}}$, maksimalna sopstvena vrednost. Ukoliko ne izvršimo normalizaciju, vrednost gradijenta, težina i izlaza će da eksplodiraju, pa greška treniranja može dostići i preko 10^{18}, iz filma desilo se :).

5.5 Arhitektura mreže i odabir optimalnih hiperparametara

Naš problem je suštinski problem regresije, pa u tom smislu nije neophodno da mreža bude previše duboka. Arhitektura koju smo realizovali je sledeća:

- **Ulaz:** Graf signal $\mathbf{X}_k$ - vektor datih ocena korisnika k, na osnovu kojih treba predvideti nedostajuću ocenu. Komponente vektora, odgovaraju čvorovima korelacione mreže. Svakom čvoru je dodeljena F_{in} vrednosti.

- **Prvi skriveni sloj:** Graf konvolucioni sloj, ovde se odigrava graf filtracija, na izlazu dobijamo set od F_{out} obeležja po čvoru. Ovde je definisan i hiperparametar K, koji jeste red filtara kojim se vrši filtracija. K određuje koliko duboka susedstva će neuralna mreža analizirati.

- **Dropout sloj:** Definisan hiparametrom p, uvodi se kao oblik regularizacije tj. zaštite od preobučavanja.

- **Linearna transformacija:** Klasičan FCNN sloj, koji ima cilj da preslika $\mathbf{R}^{F_{out}}$ u $\mathbf{R}^{F_{in}}$. tj. da omogućava nam da imamo F_{in} vrednost po čvoru na izlazu.

- **Izlaz:** Graf signal sa onoliko komponenti koliko ima čvorova u korelacionoj mreži. Jedna komponenta ima F_{in} vrednosti.

- **Aktivacione funkcije:** ReLU aktivaciona funkcija u skrivenom sloju, nakon graf filtracije. Na izlazu FC sloja, je linearna aktivacija. Standardna akrhitektura za probleme regresije.

Hiperparametri:

- $F_{in} = 1$ - svakom čvoru dodeljujemo jednu ocenu, i to i želimo na izlazu.
- Broje epoha = 40, iskustveno.
- Za ostale hiperparametre, vršimo programsko pretraživanje. Koristimo biblioteku optuna, koja u početku koristi nasumičnu pretragu, a zatim Bajesovskim pristupom predviđa kombinacije parametara koje će sa većom verovatnoćom da minimizuju zadati kriterijum. Za dobijanje i validaciju optimalnih hiperparametara koristimo trening i validacioni skup podataka. Cilj je minimizovati evaluacionu funkciju, koja ima vrlo sličan oblik loss funkciji. Ispitivaćemo vrednosti u n_trials = 150 tačaka, što bi na našem skupu hiperparametara trebalo da je dovoljno.

```
bs = trial.suggest_categorical("batch_size", [2, 6, 12, 20])
dropout_param = trial.suggest_float("dropout", 0.0, 0.5)
f_out = trial.suggest_categorical("f_out", [16, 32, 64, 128, 256])
k_order = trial.suggest_int("k_order", 1, 4)
lr = trial.suggest_float("lr", 1e-4, 1e-2, log=True)
```

Slika 24: Prostor hiperparametara

Nakon pretrage, dobili smo optimalne hiperparametre.

- $K = 3$
- $F_{out} = 256$
- Batchsize = 12
- Learningrate = $1.2548 \cdot 10^{-3}$
- Dropout = $3.2662 \cdot 10^{-2}$
  Za ovakve hiperparametre, optimizaciona (evaluciona) loss funkcija uzima minimum 0.607.

Na osnovu optunine analize prostora hiperparametara (grafici koje smo dobili nakon pretrage hiperparametara, koje, greškom, nismo sačuvali), mogli smo primetiti da su paramatri koji najviše utiču na performanse learning rate i K.

Ispostavlja se da najmanji uticaj ima hiperparametar Dropout. Takođe, vrlo mali uticaj ima F_{out}. K i F_{out} najviše utiču na broj parametara treniranja. Imajući u vidu analizu uticaja hiperparametara, možemo smanjiti F_{out}, uz to da povećamo K. Ovim smanjujemo ukupan broj trening parametara, a omogućavamo da za jedan film imamo u vidu i njegove dalje susede (ovakav pristup bi imao bolji uticaj na generalizaciju)
Broj parametara za treniranje je dat relacijom: $(K+2)F_{in}F_{out} + F_{out} + F_{in}$

5.6 Treniranje mreže i evaluacija

Za mrežu sa gornjim odabirom hiperparametara prikazujemo grešku treniranja i grešku na test skupu. Primetno je da je mreža iskonvergirala. Zbog nedostatka podataka nismo radili analizu nad validacionim skupom. Na osnovu analize grafika, moglo bi se reći da nismo ušli u zonu preoboučavanja.

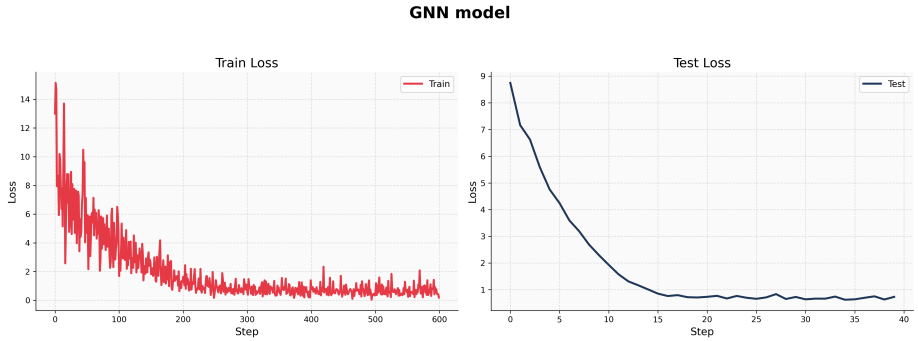

Slika 25: Train loss i Test loss

Takođe, mrežu smo obučili i sa drugim hiperparametrima, prema rezonu koji smo gore izneli. U nastavku je data greška treninja i greška na test skupu takvog modela. Ovde je $K = 5$, Dropout$= 0$ i $F_{out} = 64$.

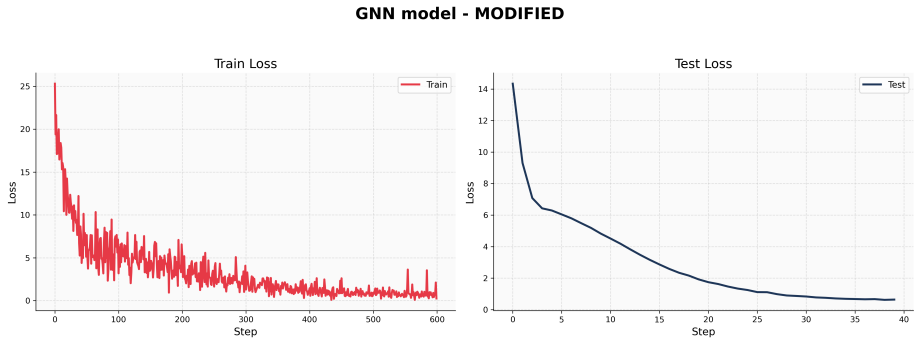

Slika 26: Train loss i Test loss - modifikovana mreža

Primeri nekih predikcija - Model 1

```
Movie name: Toy Story (1995)
Movie average rating: 3.927325487136841
UserId: 17 **** Average rating: 3.5 **** Number of ratings: 4 **** Predicted rating: 3.9 **** True rating: 5.0
UserId: 24 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 4.0 **** True rating: 5.0
UserId: 36 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 4.6 **** True rating: 4.0
UserId: 0 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 3.8 **** True rating: 4.0
UserId: 34 **** Average rating: 3.1 **** Number of ratings: 8 **** Predicted rating: 3.8 **** True rating: 4.0
UserId: 38 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 3.7 **** True rating: 3.0
UserId: 11 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 4.0 **** True rating: 5.0
UserId: 39 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 4.3 **** True rating: 3.5
UserId: 8 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 3.6 **** True rating: 4.0
UserId: 30 **** Average rating: 4.0 **** Number of ratings: 3 **** Predicted rating: 3.9 **** True rating: 4.0
UserId: 6 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 3.6 **** True rating: 3.0
UserId: 33 **** Average rating: 4.0 **** Number of ratings: 5 **** Predicted rating: 4.2 **** True rating: 4.5
UserId: 23 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 3.8 **** True rating: 4.0
UserId: 37 **** Average rating: 3.5 **** Number of ratings: 4 **** Predicted rating: 4.1 **** True rating: 4.0
UserId: 32 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 4.0 **** True rating: 3.0
UserId: 31 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 3.7 **** True rating: 4.0
UserId: 2 **** Average rating: 2.9 **** Number of ratings: 9 **** Predicted rating: 4.1 **** True rating: 5.0
UserId: 18 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 3.5 **** True rating: 2.5
UserId: 35 **** Average rating: 3.5 **** Number of ratings: 4 **** Predicted rating: 4.0 **** True rating: 4.0
UserId: 29 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 4.2 **** True rating: 3.5
```

Slika 27: Train loss i Test loss

Primeri nekih predikcija - Model 2

```
Movie name: Toy Story (1995)
Movie average rating: 3.927325487136841
UserId: 17 **** Average rating: 3.5 **** Number of ratings: 4 **** Predicted rating: 3.9 **** True rating: 5.0
UserId: 24 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 4.0 **** True rating: 5.0
UserId: 36 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 4.6 **** True rating: 4.0
UserId: 0 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 3.8 **** True rating: 4.0
UserId: 34 **** Average rating: 3.1 **** Number of ratings: 8 **** Predicted rating: 3.8 **** True rating: 4.0
UserId: 38 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 3.7 **** True rating: 3.0
UserId: 11 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 4.0 **** True rating: 5.0
UserId: 39 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 4.3 **** True rating: 3.5
UserId: 8 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 3.6 **** True rating: 4.0
UserId: 30 **** Average rating: 4.0 **** Number of ratings: 3 **** Predicted rating: 3.9 **** True rating: 4.0
UserId: 6 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 3.6 **** True rating: 3.0
UserId: 33 **** Average rating: 4.0 **** Number of ratings: 5 **** Predicted rating: 4.2 **** True rating: 4.5
UserId: 23 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 3.8 **** True rating: 4.0
UserId: 37 **** Average rating: 3.5 **** Number of ratings: 4 **** Predicted rating: 4.1 **** True rating: 4.0
UserId: 32 **** Average rating: 3.0 **** Number of ratings: 5 **** Predicted rating: 4.0 **** True rating: 3.0
UserId: 31 **** Average rating: 3.0 **** Number of ratings: 9 **** Predicted rating: 3.7 **** True rating: 4.0
UserId: 2 **** Average rating: 2.9 **** Number of ratings: 9 **** Predicted rating: 4.1 **** True rating: 5.0
UserId: 18 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 3.5 **** True rating: 2.5
UserId: 35 **** Average rating: 3.5 **** Number of ratings: 4 **** Predicted rating: 4.0 **** True rating: 4.0
UserId: 29 **** Average rating: 2.8 **** Number of ratings: 10 **** Predicted rating: 4.2 **** True rating: 3.5
```

Slika 28: Train loss i Test loss

Dodatna analiza - Model 1
Broj trening parametara = 1537

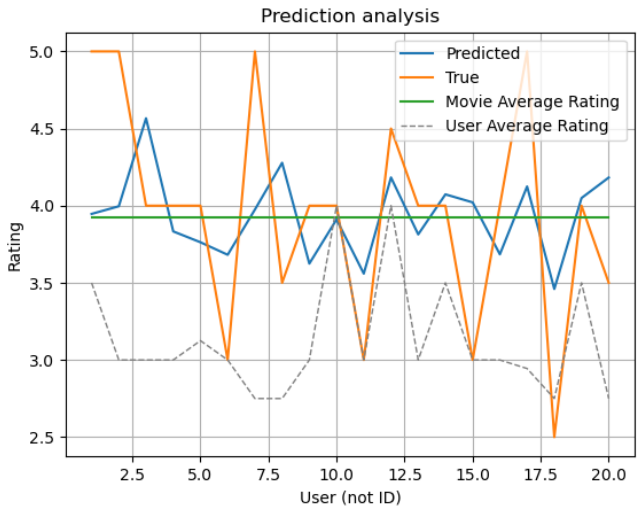

Slika 29: Analiza performansi prvog modela

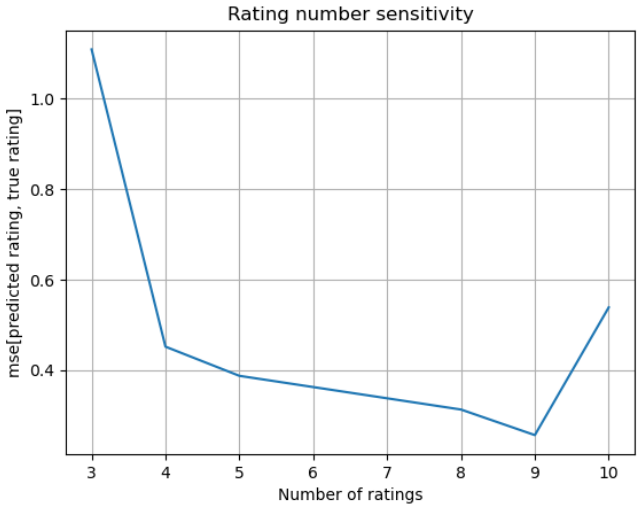

Slika 30: Zavisnost greške od broja ocena koje je korisnik dao - prvi model

Dodatna analiza - Model 2
Broj trening parametara = 513

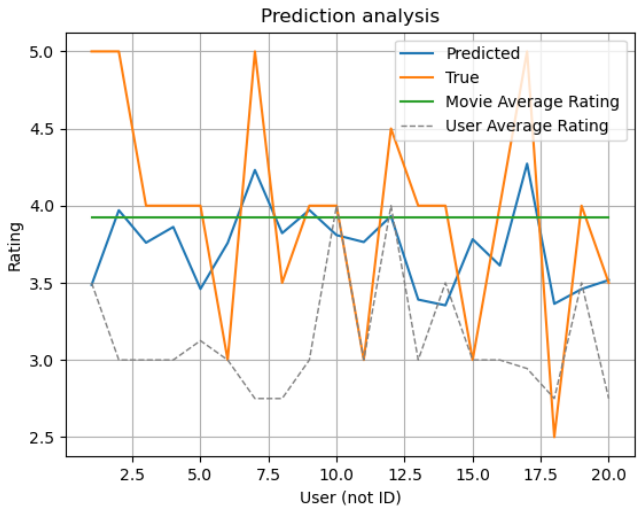

Slika 31: Analiza performansi prvog modela

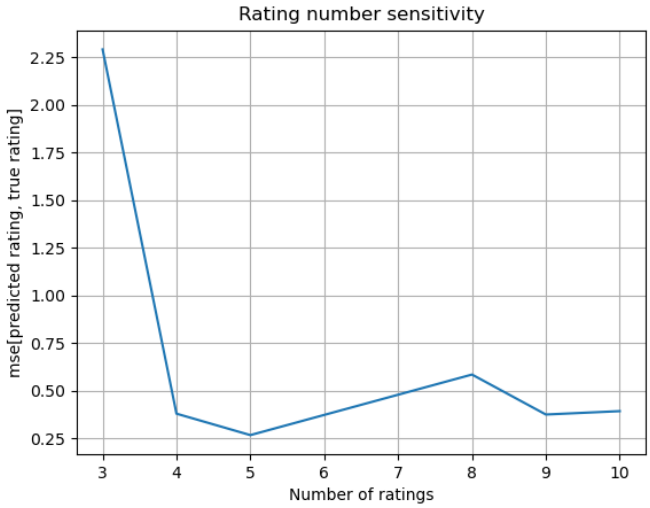

Slika 32: Zavisnost greške od broja ocena koje je korisnik dao - prvi model

Posmatrajući grafike analize performnsi, za oba modela, može se primetiti da model svoje predviđanje formira tako da više favorizuje informaciju (veze) koja generalno važi o filmu (među filmovima), nego li prethodne ocene koje je korisnik dao do trenutka predviđanja. Upravo to je osobina modela koji se zasnivaju na kolaborativnoj filtraciji. Predviđanje ocene po korisniku ima trend srednje vrednosti ocene filma na osnovu već dodeljenih ocena filmu od drugih korisnika, pri čemu se svaka posebna ocena formira tako da se uzimaju u obzir specifične veze sa dovoljno bliskim korisnicima. U skladu sa tim, može se primetiti da, vrlo često predviđanje dobro prati fluktuacije stvarnih ocena, pri čemu nije toliko agresivno, ali svakako primetno postoji. Prosečna ocena data po korisniku u ovom smislu nije parametar koji ima naročit uticaj. Međutim, sa grafika, zavisnost greške od broja ocena koje je korisnik dao, primećujemo da srednje-kvadratna greška opada. Ovo bi se moglo objasniti, da će prilikom prolaska kroz mrežu, ovakav signal sa manje nenultih elemenata da "aktivira"više čvorova u graf-konvolucionom sloju. Na taj način, u obzir će se uzeti i korelaisanosti trenutnog filma, sa većim brojem ostalih filmova koje je korisnik gledao, pa je u tom smislu veća verovatnoća da model da bolju procenu.

Treba napomenuti da postoje filmovi koji imaju mali broj korisnika, koji su im dali ocenu. U tom smislu, treniranje mreže se značajno oteževa i treba razmisliti o određenom obliku augmentacije podataka i modifikacije hiperparametara, poput broja epoha treniranja i batch size. Čak i u našem primeru koji je imao oko 170 trening elemenata i 40 test elemenata, poželjno bi bilo izvšiti augmentaciju, međutim zbog složenosti postupka pripreme podataka i manjka iskustva sa GNNs to ovde nismo radili. Takođe, u realnim primenama sigurno bi posedovali veću bazu podataka, pa je u takvoj situaciji rad olakšan. Što se tiče realnih primena ovakvog modela, treba reći da je neophodno dosta računarskih resursa, posebno za prvo treniranje, jer bi morali da treniramo model za svaki film ili par one od interesa.